

摘要

隨著社群媒體的快速發展，網路言論自由的特性促進了資訊交流，但同時也助長了網路霸凌與惡意言論的氾濫。近年來，隱喻性惡意語言成為逃避審查的常見手法，其中諧音雙關被廣泛應用於中文網路社群，以隱晦方式傳遞攻擊性內容。然而，由於現有惡意語言偵測技術主要針對顯性惡意文本，對於隱喻性惡意文本的辨識能力仍然不足，使得這些偽裝攻擊容易規避過濾機制。

本研究旨在分析惡意諧音文本的產生機制與語境特徵，並建立針對台灣文化下的隱喻性惡意語言的中文語料庫，進行模型試驗。同時，也將 NLP 模型融合語義與拼音資訊，提升模型對諧音隱喻惡意文本的偵測能力。本研究首先從台灣各大論壇網站蒐集具有惡意的諧音或地獄梗，並進一步設計提示詞以利用 LLM 擴增資料集。最後，透過結合拼音向量與語義向量的 NLP 模型，進行惡意諧音文本的辨識與分類。

實驗結果顯示，在資料生成方面，透過結合任務定義、範例、限制條件與語言背景資訊之提示詞設計，可有效提升生成資料之品質，使惡意諧音比例由 0.1 提升至 0.8。在模型表現方面，結合拼音向量之模型能達到良好表現 ($F1 = 0.80$)，優於基準之 BERT 模型 ($F1 = 0.77$)。結果顯示，拼音向量能有效補強純文字模型在處理語音隱喻時之不足，對中文惡意諧音語言之辨識具有重要貢獻。

關鍵詞: 自然語言處理、大型語言模型、提示詞設計、諧音、毒性語言偵測

Abstract

With the rapid development of social media, the nature of online free speech has facilitated information exchange, but has also contributed to the proliferation of cyberbullying and malicious content. In recent years, metaphorical malicious language has become a common strategy to evade moderation, among which homophonic puns are widely used in Chinese online communities to convey offensive meanings in a subtle manner. However, existing toxic language detection techniques primarily focus on explicit malicious text and remain insufficient in identifying implicit forms, allowing such disguised attacks to bypass filtering mechanisms.

This study aims to analyze the generative mechanisms and contextual characteristics of malicious homophonic text, and to construct a Chinese corpus of metaphorical malicious language grounded in Taiwanese cultural context for model experimentation. In addition, this research integrates semantic and pinyin information into NLP models to enhance their ability to detect homophonic metaphorical toxicity. First, malicious homophonic expressions and “dark humor” (so-called “hell jokes”) are collected from major Taiwanese online forums. Prompt engineering is then applied to leverage large language models (LLMs) for dataset augmentation. Finally, NLP models that combine pinyin embeddings with semantic embeddings are employed to identify and classify malicious homophonic text.

Experimental results show that, in terms of data generation, prompt designs incorporating task definitions, examples, constraints, and linguistic context significantly improve data quality, increasing the proportion of malicious homophonic samples from 0.1 to 0.8. In terms of model performance, models incorporating pinyin embeddings achieve strong results ($F1 = 0.80$), outperforming the baseline BERT model ($F1 = 0.77$). These findings indicate that pinyin embeddings effectively compensate for the limitations of text-only models in handling phonetic metaphors, making a significant contribution to the detection of Chinese homophonic malicious language.

Keywords: NLP, LLM, Prompt Engineering, Pun, Toxic Language Detection

1 研究動機與研究問題

隨著社群媒體的快速發展，其匿名性與自由發言的特性使其成為全球網民主要的交流平台。然而，這份自由也帶來負面影響——網路霸凌與惡意言論的氾濫。根據世界衛生組織於 2024 年發布的《學齡兒童健康行為》[董 24]，全球約百分之 17 的兒童曾遭受網路霸凌；且在 “All the Latest Cyberbullying Statistics for 2024” [Sei] 這篇文章中指出，約有百分之 25 的受害者在經歷網路霸凌後出現自殘行為、百分之 37 的受害者因此罹患憂鬱症、百分之 41 的受害者出現社交焦慮症。這些數據顯示，網路暴力已成為影響社會穩定與個人心理健康的重要議題，而惡意語言偵測系統的開發，對於維護社群媒體的言論環境至關重要。

目前，許多研究已致力於惡意語言偵測工具的開發。例如，Google 的 PerspectiveAPI[Jig24] 以及 ctextricsAI[Tex24]。然而，傳統偵測方法主要聚焦於顯性惡意言論，即包含明確攻擊性詞彙的文本，如直接侮辱、威脅或歧視性言語。但對於隱喻性惡意言論，如透過諧音、雙關語、委婉詞或文化隱喻來表達攻擊性內容，現有技術仍然存在顯著的偵測不足。根據 Chu et al.[CR16] 的研究指出，由於網路平台對於敏感詞彙的審查機制日益強化，一些使用者開始透過諧音詞取代惡意詞彙，以規避審查，進而造成偵測系統的失效。例如：「喜韓兒」表面上是中性詞，但在特定語境中，實際上是「喜憨兒」的音譯，帶有歧視與侮辱意圖；「草泥馬」在字面上指的是「羊駝」，但實際上是對某些不雅詞彙的替代用法。

這類惡意語言具有高度的語境依賴性，使得傳統基於詞彙匹配或顯性攻擊詞偵測的方法難以有效辨識。此外，惡意諧音文本的最大挑戰在於攻擊方式變化迅速，偵測系統難以迅速適應新興的諧音攻擊模式。因此，若要有效防範這類惡意言論，僅僅依靠被動的偵測是不夠的。我們需要深入理解隱喻性惡意語言的產生原則，才能預測新的變種，並提高系統的防範能力。再加上，現有的大多數惡意語言偵測研究主要針對英語語言，而中文具有完全不同的語言結構、文化背景與語用特性，使得現有技術難以直接應用於中文隱喻性惡意文本的偵測。

基於上述背景，本研究致力於分析惡意諧音文本的產生機制與語境特徵，並建立中文隱喻性惡意文字的語料庫，以補足目前惡意偵測研究對於隱喻性攻擊語言的不足。同時也利用語言模型與拼音向量來強化語言模型諧音對於惡意文本的辨識能力，並希望加以應用於語言使用建議機制，以減少無意間的語言攻擊或誤解。

2 文獻探討與回顧

2.1 惡意文句判斷

惡意文句的識別技術可分為規則為主的方法、機器學習方法與深度學習方法。傳統規則方法需要人工設計判斷規則，泛化能力有限；機器學習與深度學習則能提升自動化程度，但多數研究主要針對英文文本，中文惡意文本的處理仍相對不足。

為提升惡意文本識別的效能，本研究參考 Xu, M.; Liu[XL23]。該研究利用 RoBERTa (Robustly Optimized BERT Pretraining Approach) [LOG+19] 語言模型，其經過大規模語料訓練，可生成高品質的詞向量 (word embeddings)，並應用於惡意詞彙與句法結構的辨識。此外，該研究還透過雙向門控遞迴單元 (Bidirectional Gated Recurrent Unit, BGRU) 來捕捉上下文信息，使惡意文本檢測更加準確。為進一步提升語境理解能力，該研究整合多頭注意力機制 (Multi-head self attention)，透過加權處理 BGRU 輸出資訊，並融合詞向量，使模型能夠更精確地判斷輸入文本是否具有惡意內容。相比傳統方法，該方法不僅考量惡意詞彙本身，亦考慮上下文關係，有效提升中文惡意文本的判斷能力。

2.2 拼音向量

Yao et al.[YWHH22] 的研究指出，現今的詐騙簡訊經常透過同音換字來規避傳統基於字面匹配的詐騙檢測方法，導致現有的字詞匹配技術難以準確識別詐騙訊息。為了解決這一問題，該研究提出將拼音向量（pinying embeddings）整合至原有的詞向量，以提升對詐騙訊息的檢測能力。該研究的方法結合雙向門控遞迴單元（Bidirectional Gated Recurrent Unit, BGRU），使模型能夠同時考慮字音、字義及上下文語境，進一步增強模型對詐騙訊息的理解與識別能力。最後，該研究將 BGRU 的輸出傳入 TextCNN[Kim14]，透過卷積神經網路（Convolutional Neural Network, CNN）擷取局部特徵，以判斷輸入文本是否為詐騙簡訊。為了提高模型的泛化能力，該研究使用天鵝互動控股有限公司所收集的詐騙訊息資料集作為訓練數據，並透過 Python 模組 nlpcda，隨機替換部分漢字為同音異字，以提升模型對多樣化詐騙文本的適應性。

本研究將參考該方法，並進一步將拼音向量應用於惡意文本偵測，使語言模型能夠更精確地識別隱性諧音惡意文字，進而提升中文惡意文本的檢測能力。

2.3 情境式學習（In-Context Learning）

近年來隨著大型語言模型（LLM）在模型規模與訓練資料量上的持續擴展，其在情境式學習（In-Context Learning, ICL）[BMR+20] 上的能力亦顯著提升。情境式學習的核心概念在於模型可透過提示詞中所提供的範例與任務說明進行類比學習，進而推論任務規則並完成新的輸入，而無需對模型參數進行額外的訓練或更新。

Tom B. Brown[BMR+20] 等人於 GPT-3 的研究中指出，在提示詞中提供少量範例（few-shot examples）即可有效提升大型語言模型在多種自然語言處理任務上的表現。此外，近期研究亦指出，提示詞中的任務定義與標註說明對模型表現具有重要影響。Fan 等人（2023）[YVL+23] 進一步指出，若在提示詞中提供清楚且具體的任務定義與背景說明，模型能更準確理解任務目標，並產生品質較高且多樣性較佳的生成結果。

基於上述研究成果，本研究在提示詞的設計上結合範例、任務定義與背景說明，使模型能充分理解台灣網路文化中諧音梗的語言特性。透過此方式，搭配大型語言模型進行資料擴增（data augmentation），生成符合台灣諧音梗邏輯又具有隱性毒性之語料，以提升資料集的規模、多樣性與整體品質，進而支援後續模型訓練與評估。

3 研究方法及步驟

3.1 資料蒐集

本研究首先於台灣主要線上論壇平台（如 PTT、Dcard 等）蒐集各類主題諧音梗。在分析上述語料後，歸納出台灣網路文化中常見的諧音梗類型，並將其分類為以下幾種：

類別 A：中文諧音

利用國語中讀音相同或極為接近的字詞進行替換，包括聲母、韻母相似或僅聲調不同的情況。例如：自鯊 → 自殺

麵麵俱到（麵店招牌）→ 面面俱到

類別 B：中英諧音

將英文單字的讀音嵌入中文語法結構中，透過語音相似性形成新的語意。例如：Duck 不必 → 大可不必

類別 C：混合台語

利用國語漢字標註台語（Hokkien/Taigi）發音，形成跨語言的諧音效果。例如：踹共 → 出來講

類別 D：英文字母或注音讀音

利用英文字母名稱或注音符號的讀音組合成句。例如：UCCU → 你看看你（You see see you）

類別 E：數字諧音

利用數字的讀音與語詞相似性產生語音替代效果。例如：1314 → 一生一世

而後，本研究進一步於論壇平台蒐集具有惡意語境之諧音梗與地獄梗作為研究資料來源。透過人工篩選，共整理出 23 筆具有代表性的初始語料，並針對其語音轉換邏輯進行分析與標註，以作為後續資料生成之基礎。

表 1 展示初始語料之結構與部分範例，完整內容則詳見附錄 A。

表 1: 初始語料之結構與部分範例

text	label	logic
他真的很肚爛	1	中文肚爛本身沒什麼意思，但用台語發音為惱人的意思
爛瑜充庶	1	結合『濫竽充數』與韓國瑜（瑜）、庶民（庶）的標籤，諷刺其能力不足
除舊汰欣	1	結合「除舊佈新」與立委「徐欣瑩」之名，意指罷免徐欣瑩

3.2 提示詞設計

本研究參考 Brown 等人（2020）[BMR+20] 所提出之情境式學習（In-Context Learning）概念，以及後續提示詞設計（prompt engineering）之相關研究，將提示詞拆分為多個結構化模組，以系統性引導大型語言模型生成符合台灣語境之惡意諧音語料，進而提升生成資料之品質與穩定性。提示詞主要包含以下四個部分：

1. 概念定義

由於模型之主要任務為生成台灣語境下的惡意諧音語料，本研究於提示詞中首先明確定義中文諧音梗之語言學特性，即「語音相似」但「字義與字形分歧」。此外，將前述整理之諧音類型（如中文諧音、中英混合、台語諧音與數字諧音）納入提示內容，使模型能理解不同語音轉換機制，並據此進行多樣化生成。

2. 任務與目標

在任務設定上，本研究明確指定生成任務為「惡意諧音梗生成」，並於提示詞中定義輸出格式、生成數量及標註欄位。同時，進一步界定惡意諧音之核心特徵為「語意表面無害，但語音對應具有攻擊性或諷刺性」，以引導模型在語意與語音之間建立對應關係。

3. 角色設定

本研究採用角色提示（role prompting）策略，透過設定模型為特定領域專家，使其在生成過程中能依據該角色之知識背景與語言風格進行推理與輸出。具體而言，本研究將模型設定為熟悉台灣語言文化之語言學專家，以提升生成語料之在地性與語言自然度。提示詞中之角色描述如下：

你是台灣的語言學專家，精通中文與台語，並專門研究台灣網路文化中常見的諧音梗。

4. 限制條件設計

為避免模型生成之語料偏離研究目標或過度依賴範例，本研究於提示詞中加入限制條件，以控制生成結果之品質與分布。該設計亦為提示詞工程中常見之約束策略之一。具體限制如下：

- 不得直接使用明確之負面詞彙（如明顯髒話或攻擊性詞語）
- 內容需符合台灣在地語言文化與使用情境
- 諧音轉換需具備高度語音相似性
- 生成資料需平均分布於不同諧音類型，不得僅對初始範例進行表面變形

完整提示詞內容將附於附錄 B 中。

3.3 訓練資料集建構

本研究將設計完成之提示詞輸入大型語言模型，以生成惡意諧音語料。實驗中主要使用兩種大型語言模型：Google 開發之 Gemini Pro [Goo24] 與 OpenAI 開發之 ChatGPT [Ope24]，並透過情境式學習方式，引導模型生成符合諧音特徵之語句。每次生成 100 筆語料，並重複多次以擴充資料規模與提升多樣性。

在資料生成完成後，本研究對所有生成樣本進行人工審核，刪除不符合諧音邏輯、語意不明確或內容高度重複之資料，以確保資料品質與語言合理性。

隨後，為建構分類模型所需之訓練資料集，進一步蒐集與合成等量之非毒性諧音語料。並依據預先定義之標註準則，將所有樣本標記為「毒性」或「非毒性」兩類。最終整理形成一組平衡之標註資料集，用於後續模型之訓練與效能評估。

3.4 拼音向量表示

傳統語言模型主要依賴文字嵌入進行語意建模，較難有效捕捉語音層面的相似性。為強化模型對諧音語言之辨識能力，本研究提出一套結合語音資訊之拼音向量表示方法。

整體拼音向量之建構流程可分為兩個階段：（1）語音轉換（phonetic mapping）與（2）向量化與融合（embedding and fusion）。




圖 1: 拼音向量產生過程

1. 語音轉換 (Phonetic Mapping)

現有多數中文語言模型在處理拼音嵌入時，通常將文字統一轉換為羅馬拼音後進行建模。然而，此類方法主要針對純中文語料設計，當輸入文本同時包含英文字母與台語語音時，往往難以準確捕捉跨語言之語音對應關係。

為解決上述問題，本研究參考相關研究 [曾 18]，設計一套跨語言拼音轉換機制。首先，將中文字符轉換為注音符號，並依據預先定義之映射規則轉換為台語羅馬拼音表示。注音與台羅拼音之對應關係如表 2 所示。

此外，針對英文字母，本研究先依其語音單位轉換為對應語音表示，再映射至注音符號（表 3），最後轉換為拼音表示。此流程可統一不同語言來源之語音資訊，使其映射至相同語音空間。

2. 向量化與融合 (Embedding and Fusion)

在完成拼音轉換後，將其轉換為對應之數值表示，以作為拼音向量（pinyin embedding）。具體而言，將每個拼音單位映射為固定長度之索引序列，並轉換為向量表示。

為與原始序列特徵向量對齊，本研究將拼音序列長度統一設定為 128，不足部分以 0 進行填補（padding）。最終，將拼音嵌入與序列特徵向量進行融合，其融合方式採用向量逐元素相加（element-wise addition），以整合語意與語音資訊。

透過上述設計，本方法可有效整合中文、台語與英語等多語言語音特徵，特別適用於台灣網路語境中常見之跨語言諧音現象，進而提升模型對諧音語言之建模能力。

表 2: 注音符號與台羅拼音對應關係

注音	拼音	注音	拼音
ㄅ	p	ㄆ	ph
ㄇ	m	ㄈ	f
ㄊ	t	ㄊ	th
ㄋ	n	ㄌ	l
ㄎ	k	ㄎ	kh
ㄏ	h	ㄗ	ts
ㄘ	tsh	ㄟ	s
ㄙ	tsr	ㄙ	tshr
ㄩ	sr	ㄣ	jr
ㄗ	ts	ㄘ	tsh
ㄌ	s	ㄚ	a
ㄛ	o	ㄛ	o
ㄜ	e	ㄜ	ai
ㄝ	ei	ㄞ	au
ㄟ	ou	ㄟ	an
ㄠ	en	ㄠ	ang
ㄡ	eng	ㄡ	er
ㄩ	i	ㄨ	u
ㄩ	yu		




圖 2: 向量融合過程




圖 3: 模型架構

表 3: 英文字母語音與注音符號對應關係

英文讀音	注音	英文讀音	注音
B	ㄅ	P	ㄆ
M	ㄇ	F	ㄈ
D	ㄉ	T	ㄊ
N	ㄋ	L	ㄌ
G	ㄍ	K	ㄎ
HH	ㄏ	JH	ㄐ
CH	ㄔ	ZH	ㄗ
SH	ㄕ	S	ㄙ
Z	ㄗ	R	ㄖ
NG	ㄣ	AA	ㄚ
AE	ㄝ	AH	ㄛ
AO	ㄛ	AW	ㄜ
AY	ㄜ	EH	ㄝ
EY	ㄞ	IH	ㄟ
IY	ㄟ	OW	ㄠ
ER	ㄠ	UW	ㄡ

3.5 模型架構

本研究選用以大型中文語料 CLUECorpus [XZD20] 預先訓練之 RoBERTa [LOG+19] 模型作為基礎架構，以其良好的語意理解能力產生相對應之序列特徵向量。同時，在其嵌入層後加入拼音向量表示，以同時保留語意理解能力又能增強模型對語音相似性及諧音現象之表徵能力。而在模型輸出端，採用標準分類架構，於產生拼音向量集序列向量的融合層後接上接線性分類層 (linear layer)，以進行二元分類 (毒性／非毒性) 任務。

此外，本研究使用所建構之標註資料集對模型進行微調 (fine-tuning)，並以交叉熵 (cross-entropy) 作為損失函數，使模型能有效學習文字語義與語音特徵之結合表示，進而提升對台灣語境下諧音型毒性語言之辨識效能。

4 研究成果

本研究主要有兩項貢獻。第一，提出一套系統化之提示詞設計方法，並據此生成與建構一個以台灣網路文化為背景之諧音型毒性語言資料集；第二，提出結合台語羅馬拼音之拼音向量表示方法，以強化模型對諧音語言中語音特徵的辨識能力。

4.1 不同提示詞之影響

本研究採用隨機採樣分析的方法評估大型語言模型所生成之資料品質。依據 Xu 等人 [XSA+24] 的研究結果，對生成資料進行約 10% 的隨機抽樣，即可在模型評估結果上達到良好的代表性與可靠性。

因此，本研究自生成語料中隨機抽取 10% 之樣本，並進行人工標註與品質評估。評估指標包含以下三項：

1. 是否具有惡意語意
2. 是否符合諧音特徵

3. 資料之多樣性

表 4: 不同提示詞設計之生成資料品質

方法	具有惡意 (%)	具有諧音 (%)	惡意諧音 (%)
僅任務描述 (基準)	0.7	0.5	0.1
任務描述 + 範例	0.6	0.6	0.6
任務描述 + 範例 + 限制條件	0.6	0.7	0.6
任務描述 + 範例 + 背景資訊	0.7	0.6	0.6
任務描述 + 範例 + 限制條件 + 背景資訊	0.8	0.9	0.8

表 5: 不同提示詞之生成結果

僅任務描述	加入範例	完整提示詞
「保外就醫」	「妳的貝殼很美」	「你的穿搭風格很有大籬呆的復古感」
「哭爸」	「你要去吃自己嗎？」	「這間新開的健身房韓粉體積很大」
「大麻煩」	「這女的真能幹」	「你這個乚出」
「林北」	「你今天的妝容很台女典範」	「他的新髮型簡直是走鐘藝術的巔峰」

由表 4 及表 5 可見，不同提示詞設計對生成資料品質具有顯著影響。當提示詞中僅包含任務描述時，模型雖能生成具有台灣語境與部分負面語意之詞彙，但多為既有詞語或直接表達，缺乏明確的諧音轉換機制，未能符合「語意表面無害但語音具攻擊性」之核心定義。其中「惡意諧音」比例僅為 0.1，顯示模型難以同時滿足語音與語意的雙重條件。

當提示詞中加入範例，也就是先前蒐集的初始語料後，模型生成之語句明顯趨向表面語意中性但隱含性暗示或貶抑語意之表達形式，符合惡意諧音的定義。且其在諧音表現與惡意諧音比例上均有明顯提升，顯示範例有助於模型學習諧音轉換的基本模式。

然而，對於資料多樣性而言，背景資訊扮演更為關鍵的角色。當提示詞中明確提供台灣語境與諧音類型的說明時，模型能生成更多樣化且符合語言邏輯的語句。生成結果不僅涵蓋中文諧音，亦包含台語轉寫與注音符號等多種表現形式，顯示模型已能掌握台灣網路語境中常見之跨語言諧音模式，同時維持「語意中性、語音具攻擊性」之特性。此結果顯示，背景資訊有助於模型理解諧音生成的語言規則，而限制條件則可避免模型僅對範例進行表面變形，進而提升整體資料品質與多樣性。

綜合上述案例可見，隨著提示詞設計逐步加入範例、限制條件與背景資訊，模型由產生缺乏諧音特徵之語句，逐步轉為生成符合語音邏輯且具多樣性的惡意諧音語料。此結果進一步驗證結構化提示詞設計對於資料生成品質之關鍵影響。

4.2 資料集概述

本研究所建構之資料集共包含約 500 筆經人工標註之語料，並依比例劃分為訓練集與測試集，其中訓練集包含 400 筆資料，測試集包含 100 筆資料。整體資料中毒性與非毒性語料之分布大致平衡，比例約為 49% 與 51%，有助於避免模型在訓練過程中產生偏置問題。

在毒性語料方面，本研究進一步依語意特徵將其分類為「個人人身攻擊」、「政治諷刺言論」、「性暗示」、「粗俗語言或直接侮辱」以及「種族或特定族群歧視」等類型。如圖 4 所示，其中以個人人身攻擊與政治諷刺之比例最高，顯示台灣網路語境中的惡意諧音多集中於針對個人或公共議題之隱晦表達。

在語言形式方面，諧音語料可依其語音來源分為中文諧音、中英混合諧音、台語轉寫諧音以及數字諧音等類型。如圖 5 所示，其中以中文諧音佔比最高，其次為台語相關諧音。此分布結果與台灣實際語言使用情境一致，反映中文與台語在網路語言中的主導地位，同時也顯示跨語言混合為諧音生成的重要特徵。

相對而言，非毒性樣本則多為一般性之諧音或文字遊戲，不涉及攻擊性語意，作為模型訓練與評估之對照資料，有助於提升分類任務之判別能力。




圖 4: 資料分佈

4.3 模型表現

本研究選擇 Google 提出之 Chinese-BERT [ZCZ⁺19]、中研院 CKIP 團隊開發之 CKIP-BERT [CKI20]，以及 RoBERTa [LOG⁺19] 作為比較模型，以評估所提出拼音向量在不同模型架構下之效果。

由表 6 可見，與僅使用文字嵌入表示之基準模型相比，加入拼音向量後，各模型在 Precision、Recall 與 F1 指標上皆呈現穩定提升。此結果顯示，語音特徵能有效補足純文字表示在處理諧音語言時之不足。

此外，圖 6 所示之混淆矩陣亦顯示，在加入拼音向量後，各模型在毒性與非毒性樣本之分類準確度皆有明顯提升，顯示模型在兩類別上的判別能力均獲得改善。綜合而言，本研究所提出之拼音向量表示方法能有效強化模型對諧音型毒性語言之辨識能力，並在不同模型架構下皆展現良好之泛化效果。

在模型比較方面，RoBERTa 之整體表現最佳。此結果可能源於 RoBERTa 採用較大規模語料與改良之預訓練策略，使其在語境建模能力上優於傳統 BERT 模型，因而更能捕捉隱含於語音中的諧音語義。

5 研究限制

本研究仍存在若干限制。首先，在資料規模方面，本研究所建構之資料集僅約 500 筆語料，整體規模仍相對有限。由於資料量不足，不同模型與特徵表示方法之間的效能差異尚未能充分展現，因而對實驗結果之解釋造成一定限制。




圖 5: 諧音語言種類分佈

表 6: 不同方式的模型表現


方法	Precision (%)	Recall (%)	F1 (%)
BERT (基準)	0.77	0.77	0.77
BERT + 拼音向量	0.78	0.78	0.78
CKIP-BERT	0.79	0.78	0.78
CKIP-BERT + 拼音向量	0.79	0.79	0.79
RoBERTa	0.79	0.79	0.79
RoBERTa + 拼音向量	0.81	0.80	0.80

其次，在語音特徵表示方面，本研究主要採用台語羅馬拼音作為拼音向量表示方式。然而，實際網路語言中的諧音表達形式具有高度多樣性，尚包含數字諧音、表情符號及其他跨語言混合形式，這些語言現象尚未納入本研究之模型設計中，可能影響模型對真實語境之泛化能力。


最後，在資料分布方面，本研究所蒐集之語料仍以中文與台語為主，其他語言形式之比例相對較低。未來若能進一步平衡不同語言類型與諧音形式之分布，將有助於提升模型對多樣化語言現象之適應能力與整體辨識效能。

6 未來展望


未來研究可從以下幾個方向進一步發展。首先，可持續擴充資料集的規模與多樣性，以涵蓋更多不同形式與語境的諧音梗，進而提升模型訓練的穩定性與辨識能力。其次，可將本研究所建構之資料集與方法套用於不同的預訓練語言模型，以評估模型在不同架構下之表現差異，並進一步提升模型的泛化能力。此外，在拼音向量的設計上，未來亦可進一步擴展語音表示方式。除了目前所採用之台語羅馬拼音表示外，亦可納入數字諧音與表情符號等常見於網路語言中的元素，以更完整地捕捉台灣網路文化中多樣化的諧音表達形式。最後，本研究所建




(a) BERT(基準)




(b) BERT + 拼音向量




(c) CKIP-BERT



(d) CKIP-BERT + 拼音向量



(e) RoBERTa



(f) RoBERTa + 拼音向量

圖 6: 不同模型的混淆矩陣結果比較

構之資料集亦可作為未來相關語料庫建置的初始資料來源。透過結合提示詞生成方法，可進一步客製化並擴充資料內容，以逐步建立更完整且具代表性的諧音語言資料集。

7 結論

本研究以台灣網路文化為背景，蒐集並建構一套中文惡意諧音語料，並提出一套系統化之提示詞設計方法，以大型語言模型進行資料擴增。透過情境式學習（In-Context Learning）與結構化提示詞設計，成功提升生成資料之多樣性與語音合理性，並有效建立可用於後續模型訓練之標註資料集。

在模型方法上，本研究進一步提出結合台語羅馬拼音之拼音向量表示，並將其融入預訓練語言模型之嵌入層中，以強化模型對語音相似性與諧音現象之建模能力。實驗結果顯示，加入拼音向量後，模型在惡意諧音語言辨識任務上具有穩定且顯著之效能提升，驗證語音資訊對於此類語言現象的重要性。

綜合而言，本研究從資料建構與模型設計兩個面向出發，證明在處理以語音為核心的隱性語言現象時，單純依賴語意表示之模型具有其限制，而結合語音特徵能有效提升辨識能力。本研究結果可作為未來中文諧音語言分析、跨語言語音建模及網路內容審查系統之基礎，並提供相關研究在資料建構與模型設計上的參考依據。

參考文獻

- [BMR⁺20] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners, 2020.
- [CKI20] CKIP Lab. ckip-transformers: NLP tools for Chinese with Transformers. <https://github.com/ckiplab/ckip-transformers>, 2020. Accessed: 2026-03-16.
- [CR16] Yingchi Chu and Horst Ruthrof. The social semiotic of homophone phrase substitution in chinese netizen discourse. *Social Semiotics*, 27(1):1–16, 2016.
- [Goo24] Google. Gemini Pro, 2024. Accessed: 2026-03-16.
- [Jig24] Jigsaw Team. Perspective api, 2024. Accessed: 2026-03-16.
- [Kim14] Yoon Kim. Convolutional neural networks for sentence classification. In *Proceedings of EMNLP*, pages 1746–1751, 2014.
- [LOG⁺19] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.

- [Ope24] OpenAI. ChatGPT, 2024. Version 4.0/5.0, Accessed: 2026-03-16.
- [Sei] Lyndon Seitz. All the latest cyberbullying statistics for 2024. Accessed: 2026-03-16.
- [Tex24] Texttrics AI. Offensive language detection solution, 2024. Accessed: 2026-03-16.
- [XL23] M. Xu and S. Liu. RB_BG_MHA: A RoBERTa-based model with Bi-GRU and multi-head attention for Chinese offensive language detection in social media. *Applied Sciences*, 13(19):11000, 2023.
- [XSA⁺24] Cong Xu, Gayathri Saranathan, Mahammad Parwez Alam, Arpit Shah, James Lim, Soon Yee Wong, Foltin Martin, and Suparna Bhattacharya. Data efficient evaluation of large language models and text-to-image models via adaptive sampling, 2024.
- [XZD20] Liang Xu, Xuanwei Zhang, and Qianqian Dong. Cluecorpus2020: A large-scale chinese corpus for pre-training language model, 2020.
- [YVL⁺23] Fan Yin, Jesse Vig, Philippe Laban, Shafiq Joty, Caiming Xiong, and Chien-Sheng Jason Wu. Did you read the instructions? rethinking the effectiveness of task definitions in instruction learning, 2023.
- [YWHH22] J. Yao, C. Wang, C. Hu, and X. Huang. Chinese spam detection using a hybrid BiGRU-CNN network with joint textual and phonetic embedding. *Electronics*, 11:2418, 2022.
- [ZCZ⁺19] Zhe Zhao, Hui Chen, Jinbin Zhang, Xin Zhao, Tao Liu, Wei Lu, Xi Chen, Haotang Deng, Qi Ju, and Xiaoyong Du. UER: An open-source toolkit for pre-training models. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 241–246, Hong Kong, China, 2019.
- [曾 18] 曾華璽. 以變調與斷詞改善台語語音辨識並以諧音建置台語幽默對話特徵. 碩士論文, 國立成功大學, 台南市, 2018. 臺灣博碩士論文知識加值系統.
- [董 24] 董氏基金會心理衛生中心. 【新知】世界衛生組織研究：兒童遭受網路霸凌的比例高於疫情前, 6 2024. Accessed: 2026-03-16.

A 初始範例資料

以下為提示詞中提供給模型作為邏輯參考的初始範例：

1. {"text": "見朕騎姬", "label": 1, "logic": "發音與「見證奇蹟」相似,但字面上的意思為看皇帝騎在妃子上,具有性暗示意味"}
2. {"text": "他真的很肚爛誼", "label": 1, "logic": "中文肚爛本身沒什麼意思,但用台語發音為惱人的意思"}
3. {"text": "海淪先弄濕", "label": 1, "logic": "讀音與洗髮精品牌「海倫仙度絲」相似;但字面上具有性暗示意味"}
4. {"text": "爛瑜充庶", "label": 1, "logic": "結合『濫竽充數』與韓國瑜(瑜)、庶民(庶)的標籤,諷刺其假扮庶民、能力不足"}
5. {"text": "發論工", "label": 1, "logic": "音近「法輪功」,常用於暗諷宗教團體法輪功。"},
6. {"text": "自鯨", "label": 1, "logic": "音近「自殺」,台灣社群平台(如Dcard)常用來規避演算法降權。"},
7. {"text": "臥操", "label": 1, "logic": "音近「我肉」,常見的粗口諧音。"},
8. {"text": "煉銅", "label": 1, "logic": "音近「戀童」,指代對兒童的性偏好,屬社群禁忌語。"},
9. {"text": "除舊汰欣", "label": 1, "logic": "結合「除舊佈新」與立委「徐欣瑩」之名,意指罷免徐欣瑩。"},
10. {"text": "展翅廢翔", "label": 1, "logic": "結合「展翅飛翔」與立委「廖偉翔」之名,意指罷免廖偉翔。"},
11. {"text": "花蓮不收支傳寶", "label": 1, "logic": "結合「支付寶」與花蓮立委「傅崐萁」之名,意指罷免傅崐萁。"},
12. {"text": "撕除惡銘", "label": 1, "logic": "結合「撕除惡名」與立委「林思銘」之名,意指罷免林思銘。"},
13. {"text": "塔綠班", "label": 1, "logic": "結合「塔利班」與「綠營」,用於嘲諷民進黨支持者。"},
14. {"text": "憨粉", "label": 1, "logic": "音近「韓粉」,將韓國瑜支持者與「憨」(笨)結合。"},
15. {"text": "可撥", "label": 1, "logic": "源於遊戲實況主統神將「可悲」打錯成「可撥」,演變成嘲諷用語。"},
16. {"text": "現在還買得到黑巧克力,買不到黑人", "label": 1, "logic": "涉及黑奴貿易與種族歧視的地獄梗。"},
17. {"text": "英文字母沒有大S", "label": 1, "logic": "利用藝人「大S」過世或負面新聞(視時事而定)的惡意玩笑。"},
18. {"text": "孤兒院都沒有家長投訴", "label": 1, "logic": "利用「孤兒」沒有父母的悲劇進行嘲諷的地獄梗。"},
19. {"text": "香鮑佐蘿莉", "label": 1, "logic": "原為菜餚名,鮑魚佐意識螺絲瑪麗;「鮑」在台灣

- 成人俚語指女性私處，「蘿莉」涉及兒童，具高度性冒犯意涵。"}，
20. {"text": "花臂鹹豬手", "label": 1, "logic": "原為菜餚名，蔥燒花菇虎掌襯時蔬；「鹹豬手」是台灣常用語，指代性騷擾/摸胸行為。"}，
21. {"text": "綠白制服趴", "label": 1, "logic": "原為菜餚名，火楠翠玉白；暗示女校校服顏色（北一、中山）的性暗示。"}，
22. {"text": "小姑若給茶", "label": 1, "logic": "原為菜餚名，菌菇肉骨茶；音近「小姑若給插」（台語/中文混雜口音），具性冒犯意涵。"}，
23. {"text": "韓國妹子軟綿綿", "label": 1, "logic": "原為菜餚名，韓式燒肉糯米飯；韓國妹子代指韓國的女性，具備性暗示。"} }

B 提示詞內容

本研究在資料生成過程中使用大型語言模型進行語料擴增。為確保生成資料符合台灣網路諧音語言的特性，本研究設計了結構化提示詞（prompt），並將語言背景、任務定義、角色設定及生成限制納入提示內容。以下為實際使用之提示詞內容：

```
[breaklines=true,breakanywhere=true,xleftmargin=1em, xrightmargin=1em]
```

第0階段：諧音

在開始生成資料前，請先理解「台灣背景諧音」的語言學邏輯。諧音的核心在於「語音相似」但「字義與字形分歧」。

在台灣社群語境中，諧音主要分為以下五大類：

類別 A：中文諧音

利用國語中讀音相同或極為接近的字詞進行替換。

Eg. 自鯊 -> 自殺

麵麵俱到（麵店招牌）-> 面面俱到

類別 B：中英

將英文單字的讀音嵌入中文語法結構中。

Eg. Duck 不必 -> 大可不必

類別 C：混合台語

利用國語文字標註台語發音。

Eg. 踹共 -> 出來講

類別 D：英文字母 / 注音

利用字母或注音符號讀音組成句子。

Eg. UCCU -> 你看看你

類別 E：數字

利用數字讀音表達語意。

Eg. 1314520 -> 一生一世我愛你

第1階段：任務

角色

你是台灣的語言學專家，精通中文、台語並專門研究台灣網路文化中常見的諧音梗

任務內容

生成100個惡意諧音

核心規則

不要只修改我提供的種子：

表面意義無害但讀音具有冒犯性

限制

1. ****零負面詞彙**** 句子表面絕對不能出現「死、笨、爛、恨」等 BERT 易偵測的負向特徵詞。
2. ****台灣背景**** 使用台灣特有的生活場景（如：夜市、捷運、職場對話、選舉）。
3. ****音韻精準**** 必須符合台灣口音（考慮 n/l 不分、ㄗ/ㄘ 不分、或台語連讀變音）。

輸出格式

```
[  
  {  
    "text": "句子內容",  
    "label": 1,  
    "logic": "目標詞 -> 替代詞 | 隱藏毒性說明"  
  }  
]
```

範例以供邏輯參考

1. {"text": "見朕騎姬", "label": 1, "logic": "發音與「見證奇蹟」相似,但字面上的意思為看皇地騎在妃子上, 具有性暗示意味"}
2. {"text": "他真的很肚爛誼", "label": 1, "logic": "中文肚爛本身沒什麼意思, 但用台語發音為惱人的意思"}
3. {"text": "海淪先弄濕", "label": 1, "logic": "讀音與洗髮精品牌「海倫仙度絲」相似; 但字面上具有性暗示意味"}
4. {"text": "爛瑜充庶", "label": 1, "logic": "結合『濫竽充數』與韓國瑜（瑜）、庶民（庶）的標籤, 諷刺其假扮庶民、能力不足"}
5. {"text": "發論工", "label": 1, "logic": "音近「法輪功」, 常用於暗諷宗教團體法輪功。"},
6. {"text": "自鯊", "label": 1, "logic": "音近「自殺」, 台灣社群平台（如 Dcard）常用來規避演算法降權。"},
7. {"text": "臥操", "label": 1, "logic": "音近「我肉」, 常見的粗口諧音。"},
8. {"text": "煉銅", "label": 1, "logic": "音近「戀童」, 指代對兒童的性偏好, 屬社群禁忌語。"},
9. {"text": "除舊汰欣", "label": 1, "logic": "結合「除舊佈新」與立委「徐欣瑩」之名, 意指罷免徐欣瑩。"},
10. {"text": "展翅廢翔", "label": 1, "logic": "結合「展翅飛翔」與立委「廖偉翔」之名, 意指罷免廖偉翔。"},
11. {"text": "花蓮不收支傳寶", "label": 1, "logic": "結合「支付寶」與花蓮立委「傅崐萁」之名, 意指罷免傅崐萁。"},

12. {"text": "撕除惡銘", "label": 1, "logic": "結合「撕除惡名」與立委「林思銘」之名，意指罷免林思銘。"},
13. {"text": "塔綠班", "label": 1, "logic": "結合「塔利班」與「綠營」，用於嘲諷民進黨支持者。"},
14. {"text": "憨粉", "label": 1, "logic": "音近「韓粉」，將韓國瑜支持者與「憨」（笨）結合。"},
15. {"text": "可撥", "label": 1, "logic": "源於遊戲實況主統神將「可悲」打錯成「可撥」，演變成嘲諷用語。"},
16. {"text": "現在還買得到黑巧克力，買不到黑人", "label": 1, "logic": "涉及黑奴貿易與種族歧視的地獄梗。"},
17. {"text": "英文字母沒有大S", "label": 1, "logic": "利用藝人「大S」過世或負面新聞（視時事而定）的惡意玩笑。"},
18. {"text": "孤兒院都沒有家長投訴", "label": 1, "logic": "利用「孤兒」沒有父母的悲劇進行嘲諷的地獄梗。"},
19. {"text": "香鮑佐蘿莉", "label": 1, "logic": "原為菜餚名，鮑魚佐意識螺絲瑪麗；「鮑」在台灣成人俚語指女性私處，「蘿莉」涉及兒童，具高度性冒犯意涵。"},
20. {"text": "花臂鹹豬手", "label": 1, "logic": "原為菜餚名，蔥燒花菇虎掌襯時蔬；「鹹豬手」是台灣常用語，指代性騷擾/摸胸行為。"},
21. {"text": "綠白制服趴", "label": 1, "logic": "原為菜餚名，火楠翠玉白；暗示女校校服顏色（北一、中山）的性暗示。"},
22. {"text": "小姑若給茶", "label": 1, "logic": "原為菜餚名，菌菇肉骨茶；音近「小姑若給插」（台語/中文混雜口音），具性冒犯意涵。"},
23. {"text": "韓國妹子軟綿綿", "label": 1, "logic": "原為菜餚名，韓式燒肉糯米飯；韓國妹子代指韓國的女性，具備性暗示。"}